




Презентація до захисту КРБ на тему «Розробка програмного забезпечення для аналізу та виявлення закономірностей у даних»

Виконала:

здобувачка групи СП-41

Карпюк Катерина Василівна

Керівник роботи:

д. ф.-м. н., проф., зав. кафедри

Петрик Михайло Романович

Актуальність

- зростання обсягу табличних даних у різних сферах діяльності;
- потреба у швидкому первинному аналізі CSV-файлів;
- необхідність перевірки якості даних перед подальшим використанням;
- важливість виявлення зв'язків, тенденцій і закономірностей;
- потреба у зрозумілому поданні результатів у вигляді таблиць, графіків і висновків.

Аналіз існуючих рішень та проблематика

Рішення	Сильна сторона	Обмеження
Power BI	бізнес-дашборди	акцент на звітах
Tableau	візуальна аналітика	складніше для початкового аналізу
Jupyter Notebook	гнучкість	потрібен програмний код
Orange Data Mining	візуальні блоки	потрібне розуміння логіки аналізу

Проблема: бракує простого вебсередовища, яке послідовно проводить користувача через базовий аналіз CSV-файлу та пояснює результати.

Мета

Розробити програмне забезпечення для аналізу даних з підказками та поясненнями результатів, яке дозволяє виконувати базовий аналіз CSV-файлів без написання програмного коду.


Функціональні та нефункціональні вимоги

Функціональні:

- завантаження CSV;
- профілювання набору даних;
- аналіз якості;
- статистика і графіки;
- кореляції та закономірності;
- базові ML-моделі;
- історія дій користувача.


Нефункціональні:

- робота через браузер;
- зрозумілий інтерфейс;
- API між клієнтом і сервером;
- сесійний доступ;
- можливість розширення.




Діаграма варіантів використання


Діаграма діяльності



Архітектура ПЗ



Модель бази даних



Методи аналізу та моделі

- описова статистика;
- аналіз якості;
- Z-score;
- Pearson/Spearman;
- лінійна регресія;
- логістична регресія;
- Random Forest;
- метрики якості моделей.

Реалізований інтерфейс

ЗМІСТ АНАЛІЗУ
PatternLab

1. Дані

2. Очищення

3. Профіль

4. Викиди

5. Аналіз

6. Рейтинг

7. Моделі

8. Звіт

Історія

admin

Вийти

Профіль набору даних

1. Набір даних прийнято
10000 рядків, 22 коло...

2. Якість даних перевірено
План якості даних уж...

3. Зміст колонок описано
3 повідомлень якості...

4. Закономірності досліджено
Є статистика, розподі...

5. Ціль аналізу визначено
Оберіть цільову коло...

6. Моделі оцінено
Порівняйте моделі кл...

7. Висновок сформовано
Сформулюйте підсумко...

Структура і якість

На цьому етапі варто зрозуміти, з чого складається CSV, які колонки можуть бути цільовими і які обмеження має набір даних.

Оновити профіль

Рядки 10000	Колонки 22	Вибірка 10000 з 253680	Числові 22	Категоріальні 5
Пропуски 0	Дублікати 74	Цільові ознаки 19	Метадані 0%	

Попередження якості

Виявлено дублікати рядків
Знайдено 74 повних дублікатів (0.74%). Їх варто переглянути, щоб не спотворити статистику та навчання моделей.

Є закодовані категоріальні ознаки
Числові коди можуть означати класи або категорії. Для коректної інтерпретації бажано описати їх у словнику колонок.
Колонки: Diabetes_012, GenHlth, Age, Education, Income

Можливий дисбаланс класів
Для частини потенційних цільових колонок один клас суттєво переважає. У такому випадку ассигасу може бути оманливою, тому слід дивитися balanced accuracy, macro F1 і матрицю помилок.
Колонки: AnyHealthcare, CholCheck, HeartDiseaseorAttack, HvyAlcoholConsump, NoDocbcCost

Потенційні цільові колонки

Система пропонує колонки з невеликою кількістю класів. Остаточний вибір залежить від мети дослідження.

Машинне навчання

ЗМІСТ АНАЛІЗУ PatternLab

1. Дані
2. Очищення
3. Профіль
4. Викиди
5. Аналіз
6. Рейтинг
7. Моделі
8. Звіт
- Історія

admin

Вийти

Моделі навчені (train: 8000, test: 2000)

✓ **Моделювання завершено**
100%

1. Перевірка цілі
2. Вибір ознак
3. Обробка пропусків
4. Навчання моделей
5. Розрахунок метрик

Результат збережено для поточного користувача.

Режим
Класифікація

Вибірка
**10000 з
253680**


Навчання
8000

Тест
2000

Ознак
19

Після кодування
19

Ціль
Diabetes_012



Автоматичні висновки

Найкращий результат за balanced accuracy показує Logistic Regression: 0.5149.

Розподіл класів незбалансований, тому balanced accuracy і macro F1 важливіші за звичайну accuracy.

За Random Forest найбільший внесок у прогноз має ознака BMI (важливість 0.2065).

Порівняння моделей слід використовувати як дослідницький орієнтир, а не як остаточний доказ причинності.

Використана вибірка

Використовується 10000 з 253680 рядків (3.94%).

Тестування

Таблиця 1 – Порівняння часу виконання

Операція	1000 рядків	50000 рядків	100000 рядків
Профілювання набору даних	0,034 с	0,155 с	0,183 с
План очищення / аналіз якості	0,096 с	1,036 с	1,799 с
Статистичний аналіз	0,034 с	0,072 с	0,126 с
Кореляція між двома ознаками	0,008 с	0,013 с	0,029 с
Кореляційна матриця	0,014 с	0,076 с	0,078 с
Рейтинг закономірностей	0,054 с	0,131 с	0,165 с
Машинне навчання	1,187 с	10,950 с	29,006 с

Практичні результати та висновки

Посилання на репозиторій із вмістом КРБ:

<https://github.com/libertasss9/dyplomna>

Посилання на опублікований збірник із тезами:

<https://elartu.tntu.edu.ua/bitstream/lib/52163/1/book.pdf>



Дякую за увагу!